Predicción jerárquica de demanda en retail mediante modelos basados en árboles y redes LSTM con reconciliación jerárquica e interpretabilidad SHAP: aplicación al dataset M5 Forecasting (Walmart)

Universitat Oberta de Catalunya

Tatyana Silchenko Kozyrieva

Área 1

Máster en Ciencia de Datos

Nombre del director/a de TF:
Aarón Montero Montero

Nombre del/de la PRA:
Susana Acedo

1 de marzo de 2026

UNIVERSITAT DE BARCELONA

Esta obra esta sujeta a una licencia de Reconocimiento
https://creativecommons.org/licenses/by-nc/3.0/es/

Ficha Del Trabajo Final

Título del trabajo:	Predicción jerárquica de demanda en retail mediante modelos basados en árboles y redes LSTM con reconciliación jerárquica e interpretabilidad SHAP: aplicación al dataset M5 Forecasting (Walmart)
Nombre del autor/a:	Tatyana Silchenko Kozyrieva
Nombre del director/a de TF:	Aarón Montero Montero
Nombre del/de la PRA:	Susana Acedo
Fecha de entrega:	1 de marzo de 2026
Titulación o programa:	Máster en Ciencia de Datos
Área del trabajo final:	Área 1
Idioma del trabajo:	Castellano
Palabras clave:	time series forecasting; retail demand; machine learning; XGBoost; LightGBM; SHAP values; M5 Forecasting; interpretability; hierarchical forecasting; forecast reconciliation

Resumen del trabajo

Este Trabajo Final de Máster desarrolla un sistema de predicción jerárquica de demanda en retail utilizando el dataset M5 Forecasting – Walmart, caracterizado por su estructura multinivel y su elevada dimensionalidad temporal y categórica. El proyecto implementará y evaluará modelos basados en árboles de decisión (Random Forest, XGBoost y LightGBM) para la predicción simultánea de múltiples series temporales, priorizando eficiencia computacional y capacidad de generalización. De forma complementaria, se implementará un modelo basado en redes neuronales recurrentes (LSTM) con el objetivo de comparar su capacidad para capturar dependencias temporales de largo plazo frente a los modelos tabulares. Se incorporará reconciliación jerárquica mediante el método MinT (Minimum Trace), utilizando Bottom-Up como referencia comparativa, con el objetivo de garantizar coherencia estructural entre los distintos niveles de agregación del dataset. Se incorporará un análisis de interpretabilidad mediante SHAP para cuantificar la contribución marginal de las variables explicativas y analizar la estabilidad del modelo en distintos niveles jerárquicos. El trabajo se orienta a construir una solución reproducible, evaluable mediante métricas estándar del dominio (RMSE, MAE y WRMSSE, métrica oficial del dataset M5) y aplicable a escenarios reales de planificación de inventario.

Abstract

This Master's Thesis develops a hierarchical demand forecasting system for the retail sector using the M5 Forecasting – Walmart dataset, characterized by its multi level structure and high temporal and categorical dimensionality. The project will implement and evaluate tree based models (Random Forest, XGBoost, and LightGBM) for the simultaneous prediction of multiple time series, prioritizing computational efficiency and generalization capability. In addition, a recurrent neural network model (LSTM) will be implemented to compare its ability to capture long term temporal dependencies against tabular models. Hierarchical reconciliation will be incorporated through the MinT (Minimum Trace) method, using Bottom Up as a comparative baseline, with the aim of ensuring structural coherence across the different aggregation levels of the dataset. An interpretability analysis using SHAP will be included to quantify the marginal contribution of explanatory variables and assess model stability across hierarchical levels. The work aims to build a reproducible solution, evaluated through standard domain metrics (RMSE, MAE, and WRMSSE—the official metric of the M5 dataset), and applicable to real world inventory planning scenarios.

Índice general

1. Módulo 1 **6**
1.1. Descripción de la propuesta y justificación del interés . . . 6
1.2. Motivación personal . . . 6
1.3. Hipótesis . . . 7
1.4. Objetivos . . . 7
1.4.1. Objetivo principal . . . 7
1.4.2. Objetivos secundarios . . . 7
1.5. Metodología . . . 8
1.5.1. Revisión del estado del arte . . . 8
1.5.2. Preparación del conjunto de datos . . . 8
1.5.3. Modelado . . . 8
1.5.4. Interpretabilidad . . . 9
1.5.5. Visualización . . . 9
1.5.6. Enfoque de trabajo . . . 9
1.6. Planificación del proyecto . . . 10
1.6.1. Módulo 1 – Definición y planificación del TFM . . . 10
1.6.2. Módulo 2 – Estado del arte . . . 10
1.6.3. Módulo 3 – Diseño e implementación del sistema . . . 10
1.6.4. Módulo 4 – Redacción de la documentación del TFM . . . 11
1.6.5. Módulo 5 – Defensa del proyecto . . . 11
1.6.6. Planificación del proyecto . . . 12
1.6.7. Gestión de riesgos del proyecto . . . 14
1.7. Impacto en sostenibilidad, ético-social y diversidad . . . 15
Bibliografía . . . 16

Capítulo 1

Módulo 1

1.1. Descripción de la propuesta y justificación del interés

La predicción de demanda condiciona directamente decisiones de reposición, planificación logística y optimización de inventarios. En entornos retail con alta granularidad y múltiples niveles jerárquicos, el modelado requiere estructuras que equilibren precisión y escalabilidad.

El dataset M5 constituye un benchmark relevante por su complejidad estructural y por incorporar información temporal, categórica y de calendario, lo que permite abordar el problema desde una perspectiva de feature engineering intensiva.

Los modelos basados en árboles resultan especialmente adecuados en este contexto por su capacidad para modelar relaciones no lineales, su robustez ante escenarios de alta dimensionalidad, su buen rendimiento en entornos tabulares con variables derivadas y su mayor eficiencia computacional frente a modelos puramente secuenciales.

La incorporación de SHAP permite analizar coherencia y estabilidad del modelo, facilitando su interpretación en un entorno profesional donde la explicabilidad es un requisito operativo.

1.2. Motivación personal

La elección de esta temática responde a un doble interés. Por un lado, profesional, dado que la predicción de demanda y la modelización de datos complejos constituyen áreas estratégicas dentro de la ingeniería de datos y la analítica avanzada. Por otro, académico, al permitir profundizar en técnicas de machine learning aplicadas a series temporales jerárquicas, así como en metodologías de evaluación rigurosas e interpretabilidad de modelos.

El dataset M5 Forecasting – Walmart ofrece un entorno de alta complejidad estructural que permite abordar un problema realista y exigente, alineado con escenarios profesionales actuales.

Asimismo, el trabajo permite analizar el equilibrio entre complejidad modelística y eficiencia computacional, cuestión relevante tanto desde la perspectiva técnica como estratégica.

1.3. Hipótesis

Los modelos basados en árboles, combinados con técnicas de reconciliación jerárquica, pueden ofrecer un rendimiento competitivo frente a modelos LSTM en la predicción jerárquica de demanda, manteniendo un menor coste computacional y proporcionando un mayor grado de interpretabilidad mediante el uso de SHAP.

1.4. Objetivos

1.4.1. Objetivo principal

Desarrollar y evaluar un sistema de predicción jerárquica de demanda aplicado al dataset M5 Forecasting – Walmart, comparando modelos basados en árboles y redes LSTM, incorporando reconciliación jerárquica mediante MinT e interpretabilidad mediante SHAP, con el fin de analizar su rendimiento predictivo y su eficiencia computacional en un contexto multinivel.

1.4.2. Objetivos secundarios

- Preparar y transformar el dataset M5 para su uso en modelos basados en árboles.
- Entrenar y comparar modelos como Random Forest, XGBoost y LightGBM.
- Evaluar el rendimiento mediante métricas adecuadas (RMSE, MAE y WRMSSE, métrica oficial del dataset M5).
- Analizar la importancia y contribución de las variables mediante SHAP values.
- Integrar la reflexión sobre sostenibilidad, ética y diversidad (CCEG).
- Implementar técnicas de reconciliación jerárquica (Bottom-Up y MinT) sobre las predicciones generadas por los distintos modelos, con el fin de garantizar coherencia estructural entre niveles agregados y desagregados.
- Desarrollar un modelo LSTM multiserie para comparar su rendimiento frente a los modelos basados en árboles.
- Analizar el coste computacional y la eficiencia relativa de los distintos enfoques modelísticos.
- Desarrollar un panel de visualización en Power BI para comunicar resultados y facilitar la interpretación de las predicciones y explicaciones del modelo.

1.5. Metodología

1.5.1. Revisión del estado del arte

La revisión del estado del arte abordará las principales técnicas de forecasting aplicadas al sector retail, con especial atención a modelos basados en árboles adaptados a series temporales y a los enfoques contemporáneos de interpretabilidad, particularmente mediante el uso de SHAP.

Esta revisión servirá de base para seleccionar técnicas y métricas que guiarán el desarrollo y comparación de los modelos propuestos.

1.5.2. Preparación del conjunto de datos

La preparación del conjunto de datos incluirá la transformación del problema a formato supervisado mediante la generación de variables lag y agregaciones móviles (rolling windows), así como la incorporación de variables de calendario y eventos relevantes. Asimismo, se aplicarán técnicas de codificación categórica eficientes y se establecerá una separación temporal estricta entre conjuntos de entrenamiento, validación y prueba, evitando cualquier forma de data leakage.

Esta preparación permitirá a los modelos basados en árboles y a la LSTM capturar patrones temporales y jerárquicos de manera consistente.

1.5.3. Modelado

El proceso de modelado se estructurará en dos enfoques complementarios.

En primer lugar, se desarrollarán modelos basados en árboles (Random Forest, XGBoost y LightGBM), adaptando el problema temporal a un formato supervisado mediante generación de variables lag y agregaciones móviles. Estos modelos permitirán capturar relaciones no lineales y gestionar eficientemente la alta dimensionalidad del dataset.

En segundo lugar, se implementará un modelo basado en redes neuronales recurrentes tipo LSTM, orientado a capturar dependencias temporales de largo plazo sin necesidad de ingeniería manual intensiva de características.

El modelo LSTM se planteará como un modelo global multiserie, entrenado simultáneamente sobre múltiples series del dataset, con el fin de capturar patrones compartidos y permitir su posterior reconciliación jerárquica bajo el mismo esquema aplicado a los modelos basados en árboles.

Las predicciones generadas por el modelo LSTM serán igualmente sometidas a los mismos procedimientos de reconciliación jerárquica, garantizando la coherencia estructural entre niveles y la comparabilidad directa entre enfoques.

Posteriormente, se aplicarán técnicas de reconciliación jerárquica, comenzando por el enfoque Bottom-Up y evaluando la viabilidad de implementar el método MinT, con el objetivo de asegurar coherencia entre predicciones de distintos niveles agregados.

El método MinT (Minimum Trace) permite reconciliar predicciones jerárquicas ajustando las previsiones base mediante una combinación lineal óptima que minimiza la traza de la matriz de varianzas del error de reconciliación. A diferencia del enfoque Bottom-Up, que simplemente

agrega predicciones desde el nivel más desagregado, MinT incorpora información sobre la estructura de correlación entre errores, produciendo estimaciones coherentes y estadísticamente más eficientes bajo supuestos razonables (Wickramasuriya, 2019).

La estimación de la matriz de covarianzas de errores se realizará a partir de los residuos obtenidos en validación temporal, siguiendo las recomendaciones metodológicas propuestas en la literatura especializada.

La comparación entre enfoques se realizará mediante evaluación out-of-sample, utilizando métricas RMSE, MAE y WRMSSE, esta última especialmente relevante por constituir la métrica oficial del dataset M5 Forecasting.

1.5.4. Interpretabilidad

El análisis de interpretabilidad incluirá el cálculo de valores SHAP tanto a nivel global como local, permitiendo examinar la contribución marginal de cada variable explicativa. Se analizará la consistencia entre la importancia global estimada y el comportamiento temporal observado, identificando las variables más influyentes en los distintos niveles jerárquicos.

El análisis mediante SHAP se aplicará sobre las predicciones generadas por los modelos base antes del proceso de reconciliación, dado que esta última constituye un ajuste estructural posterior y no forma parte del mecanismo interno de aprendizaje del modelo.

Este análisis facilitará la comprensión del comportamiento del modelo y permitirá interpretar la contribución de las variables en distintos niveles jerárquicos.

1.5.5. Visualización

Se desarrollará un panel en Power BI para mostrar las predicciones y explicaciones, orientado a la comunicación de resultados técnicos y la interpretación de los modelos.

1.5.6. Enfoque de trabajo

El proyecto se organizará de forma iterativa, siguiendo un esquema inspirado en metodologías ágiles. Cada módulo del aula funcionará como un ciclo de trabajo con entregables definidos, lo que permite revisar avances y ajustar tareas de manera progresiva.

El desarrollo del proyecto seguirá un enfoque incremental. En una primera fase se construirá un pipeline reproducible basado en modelos de árboles, asegurando estabilidad y validación temporal adecuada. Posteriormente, se implementará la reconciliación jerárquica mediante MinT para garantizar coherencia estructural. Una vez consolidado este marco, se desarrollará el modelo LSTM con fines comparativos. Este enfoque secuencial permite priorizar la robustez metodológica antes de incorporar modelos de mayor complejidad computacional.

Esta organización metodológica permitirá además alinear cada fase del proyecto con los hitos temporales previstos en la planificación.

1.6. Planificación del proyecto

1.6.1. Módulo 1 – Definición y planificación del TFM

Periodo: 18/02/2026 – 01/03/2026

En esta fase inicial se define el alcance del trabajo, concretando el tema del TFM, los objetivos de investigación y la metodología general del proyecto. Asimismo, se realiza una primera revisión exploratoria del dataset M5 con el fin de comprender su estructura, variables disponibles y posibles limitaciones. Finalmente, se redacta la propuesta formal del TFM, incluyendo la descripción del problema, los objetivos, el enfoque metodológico y una planificación preliminar del desarrollo del trabajo.

1.6.2. Módulo 2 – Estado del arte

Periodo: 02/03/2026 – 22/03/2026

Durante este módulo se lleva a cabo la revisión bibliográfica y técnica relacionada con el problema abordado en el TFM. Se analizan trabajos académicos y aplicaciones industriales en el ámbito del forecasting en retail, con especial atención a modelos basados en árboles, técnicas de series temporales y métodos de interpretabilidad de modelos. A partir de este análisis se redacta el capítulo de estado del arte, donde se contextualiza el problema, se describen los enfoques existentes y se justifica la metodología adoptada en el proyecto.

1.6.3. Módulo 3 – Diseño e implementación del sistema

Periodo: 23/03/2026 – 10/05/2026

Este módulo concentra la mayor parte del desarrollo técnico del proyecto. En primer lugar se realiza la preparación del dataset, incluyendo limpieza de datos, análisis exploratorio y verificación de la coherencia de las series temporales. Posteriormente se aplican transformaciones supervisadas para la generación de variables predictoras, como lags temporales, ventanas móviles y codificación de variables categóricas.

Una vez preparado el conjunto de datos, se desarrollan y entrenan diferentes modelos predictivos basados en algoritmos de árboles (RF, XGBoost y LightGBM), utilizando esquemas de validación temporal adecuados para series temporales. Sobre las predicciones obtenidas se aplican técnicas de reconciliación jerárquica, como Bottom-Up y MinT, con el objetivo de garantizar coherencia entre los distintos niveles de agregación.

Adicionalmente se realiza un análisis de interpretabilidad mediante valores SHAP, que permite identificar las variables más influyentes en las predicciones y analizar la estabilidad del modelo. De forma complementaria se implementa un modelo basado en redes neuronales recurrentes (LSTM) para comparar su comportamiento con los modelos basados en árboles. Finalmente se lleva a cabo una evaluación comparativa de los modelos mediante métricas como RMSE, MAE y WRMSSE, así como un análisis del coste computacional y de la interpretabilidad de cada enfoque.

1.6.4. Módulo 4 – Redacción de la documentación del TFM

Periodo: 11/05/2026 – 02/06/2026

En esta fase se elabora la memoria del TFM integrando los resultados obtenidos durante el desarrollo técnico. Se redactan los distintos capítulos del documento, incluyendo introducción, estado del arte, metodología, resultados experimentales y conclusiones. Posteriormente se realiza un proceso de revisión y ajuste del documento con el fin de mejorar la claridad de la exposición, la coherencia del contenido y la presentación de resultados. Finalmente se prepara el material de presentación del proyecto, incluyendo las diapositivas y el vídeo explicativo requeridos para la defensa.

1.6.5. Módulo 5 – Defensa del proyecto

Periodo: 05/06/2026 – 26/06/2026

La última fase del proyecto corresponde a la entrega oficial de la documentación final y a la preparación de la defensa pública del TFM. Durante este periodo se revisa la versión definitiva del documento, se realiza la entrega al tribunal y se prepara la exposición del trabajo. La defensa consiste en una presentación del proyecto ante el tribunal, donde se describen el problema abordado, la metodología aplicada, los resultados obtenidos y las principales conclusiones del estudio.

1.6.6. Planificación del proyecto

A continuación se presenta un resumen estructurado de la planificación del proyecto, donde se recogen las fases, subtareas, requisitos y hitos asociados. Los identificadores utilizados (M1, M2, M3-1, etc.) se mantienen de forma coherente para facilitar su correspondencia con el calendario del apartado siguiente.

ID	Fase (Módulo)	Periodo	Requisito	Actividades principales	Hito
M1	Definición (M1)	18-feb – 1-mar	-	Tema, objetivos, metodología, planificación	Propuesta aprobada
M2	Estado del arte (M2)	2-mar – 22-mar	M1 completado	Revisión bibliográfica, redacción capítulo 2	Capítulo del estado del arte validado
M3	Implementación (M3)	23-mar – 10-may	M2 completado	Desarrollo técnico completo	Pipeline técnico funcional
M3-1	Preparación de datos	23-mar – 27-mar	M2 completado	Limpieza inicial y revisión de datos	Dataset limpio y coherente
M3-2	Transformación supervisada	28-mar – 4-abr	Dataset limpio	Generación de lags, rolling windows, codificación categórica	Dataset listo para modelado
M3-3	Modelado Árboles (v1)	5-abr – 15-abr	Dataset preparado	Entrenamiento RF, XGBoost, LightGBM + validación temporal	Baseline entrenado y evaluado
M3-4	Reconciliación jerárquica	16-abr – 22-abr	Predicciones base	Implementación Bottom-Up y MinT	Predicciones jerárquicamente coherentes
M3-5	Interpretabilidad (SHAP)	23-abr – 30-abr	Modelos de árboles estables	Cálculo global/local, análisis estabilidad	Informe de importancia de variables
M3-6	LSTM multiserie	1-may – 7-may	Dataset preparado	Implementación y entrenamiento LSTM + generación de predicciones base para posterior reconciliación jerárquica	Modelo LSTM entrenado y predicciones reconciliadas coherentes
M3-7	Evaluación comparativa	8-may – 10-may	Todos los modelos	Comparación métricas RMSE/MAE/WRMSSE + coste computacional	Resultados consolidados
M4	Redacción del TFM	11-may – 2-jun	M3 completado	Redacción de la documentación	Documento final entregado

ID	Fase (Módulo)	Periodo	Requisito	Actividades principales	Hito
M4-1	Memoria preliminar	11-may – 15-may	M3 completado	Redacción inicial con resultados	Documento preliminar completo
M4-2	Memoria final	16-may – 24-may	Memoria preliminar	Revisión final y ajustes	Documento final entregado
M4-3	Presentación	25-may – 2-jun	Memoria final	Vídeo y diapositivas	Presentación audiovisual preparada
M5	Defensa del proyecto	3-jun – 26-jun	M4 completado	Entrega de la documentación final y defensa	Entrega al tribunal y defensa
M5-1	Entrega tribunal	5-jun	M4	Documentación final	Entrega oficial
M5-2	Defensa pública	26-jun	Entrega al tribunal	Exposición pública	Defensa realizada

Tabla 1.1: Resumen de la planificación del proyecto

En la Figura 1.1 se representa la planificación del proyecto mediante un diagrama de Gantt. Los códigos de cada fase y subtarea (M1, M2, M3-1...) coinciden con los utilizados en la Tabla 1.1, permitiendo visualizar de forma integrada la duración y la secuencia lógica de las actividades.

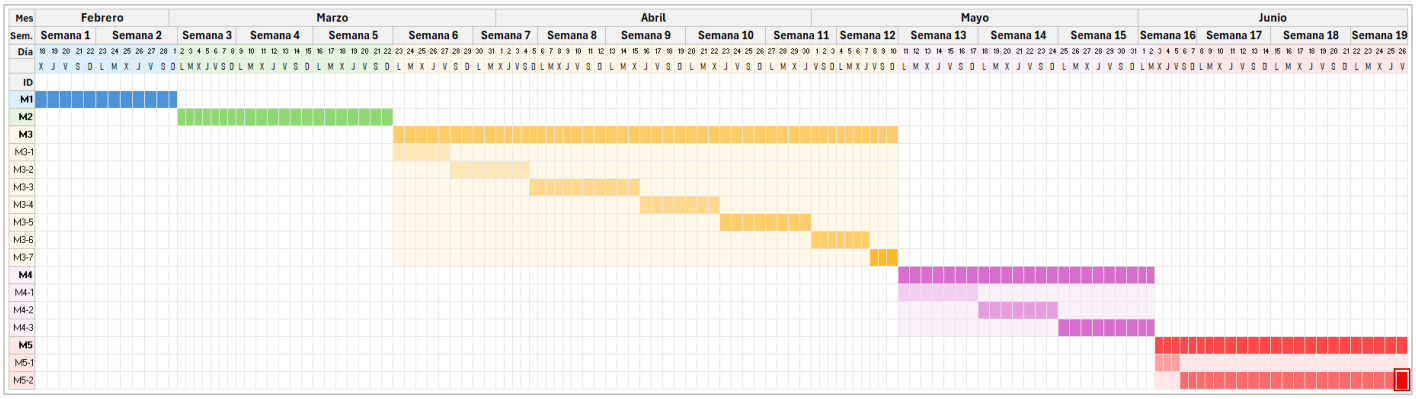

Figura 1.1: Calendario de la planificación del proyecto (formato Gantt).

La planificación permite solapamientos controlados entre fases, iniciando tareas como interpretabilidad o reconciliación jerárquica una vez establecida una primera versión del modelo base. Esto optimiza el tiempo disponible y reduce riesgos de acumulación de tareas en fases finales.

1.6.7. Gestión de riesgos del proyecto

Se identifican los siguientes riesgos potenciales:

- **Coste computacional elevado del modelo LSTM**
  Probabilidad: Media
  Impacto: Alto
  Mitigación: uso de subconjuntos jerárquicos y reducción de dimensionalidad inicial.

- **Dificultad en implementación de MinT**
  Probabilidad: Media
  Impacto: Medio
  Mitigación: priorizar Bottom-Up como método base garantizado.

- **Rendimiento similar entre modelos sin diferencias significativas**
  Probabilidad: Media
  Impacto: Bajo
  Mitigación: enfocar el análisis en interpretabilidad y eficiencia computacional.

- **Desviaciones en la planificación por complejidad técnica**
  Probabilidad: Media
  Impacto: Medio
  Mitigación: desarrollar primero un pipeline mínimo reproducible antes de optimizaciones avanzadas.

- **Riesgo de data leakage en validación temporal**
  Probabilidad: Media
  Impacto: Alto
  Mitigación: validación walk-forward estricta y separación clara por horizonte.

La gestión de riesgos se integrará de forma dinámica en la planificación temporal del proyecto. Cada hito técnico definido en la tabla de planificación funcionará como punto de control para evaluar desviaciones y activar medidas de mitigación, especialmente en las fases de modelado y reconciliación jerárquica.

Cada riesgo será evaluado al final de su fase correspondiente, usando los hitos técnicos como punto de control.

1.7. Impacto en sostenibilidad, ético-social y diversidad

Desde la dimensión de sostenibilidad, una mejora en la precisión de los modelos de predicción de demanda puede contribuir a reducir la sobreproducción, el desperdicio de productos y los costes logísticos asociados al transporte y almacenamiento, alineándose con objetivos de eficiencia operativa y reducción del impacto ambiental.

Asimismo, se considerará la eficiencia computacional y energética de los modelos desarrollados, analizando el impacto relativo de arquitecturas más complejas como LSTM frente a modelos basados en árboles, en línea con enfoques de inteligencia artificial sostenible.

En cuanto al comportamiento ético y responsabilidad social, el dataset M5 se encuentra completamente anonimizado, sin incluir datos personales, garantizando el respeto a la privacidad y el cumplimiento de normativas de protección de datos. Además, se enfatiza que los modelos desarrollados deben utilizarse como herramientas de apoyo a la toma de decisiones y no como mecanismos automatizados excluyentes.

Finalmente, el uso de datasets públicos procedentes de plataformas abiertas como Kaggle fomenta la accesibilidad, la igualdad de oportunidades en investigación y la colaboración global, promoviendo la diversidad en el desarrollo y evaluación de soluciones de inteligencia artificial.

Bibliografía

Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., & Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. Computational Statistics & Data Analysis, 55(9), 2579–2589. https://doi.org/10.1016/j.csda.2011.03.006

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). *LightGBM: A highly efficient gradient boosting decision tree*. Advances in Neural Information Processing Systems, 30.

Lundberg, S. M., & Lee, S.-I. (2017). *A unified approach to interpreting model predictions*. Advances in Neural Information Processing Systems, 30.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). *The M5 accuracy competition: Results, findings and conclusions*. International Journal of Forecasting, 36(1), 54–74. https://doi.org/10.1016/j.ijforecast.2019.12.005

Walmart & Kaggle. (2020). *M5 Forecasting - Accuracy* [Dataset]. Kaggle. `https://www.kaggle.com/competitions/m5-forecasting-accuracy`

Wickramasuriya, S. L., Athanasopoulos, G., & Hyndman, R. J. (2019). Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. International Journal of Forecasting, 35(2), 558–575. https://doi.org/10.1016/j.ijforecast.2018.11.006