Predicción jerárquica de demanda en retail mediante modelos basados en árboles y redes LSTM con reconciliación jerárquica e interpretabilidad SHAP: aplicación al dataset M5 Forecasting (Walmart)

Universitat Oberta de Catalunya

Tatyana Silchenko Kozyrieva

Área 1

Máster en Ciencia de Datos

Nombre del director/a de TF:
Aarón Montero Montero

Nombre del/de la PRA:
Susana Acedo

22 de marzo de 2026

UNIVERSITAT DE BARCELONA

Esta obra esta sujeta a una licencia de Reconocimiento
https://creativecommons.org/licenses/by-nc/3.0/es/

Ficha Del Trabajo Final

Título del trabajo:	Predicción jerárquica de demanda en retail mediante modelos basados en árboles y redes LSTM con reconciliación jerárquica e interpretabilidad SHAP: aplicación al dataset M5 Forecasting (Walmart)
Nombre del autor/a:	Tatyana Silchenko Kozyrieva
Nombre del director/a de TF:	Aarón Montero Montero
Nombre del/de la PRA:	Susana Acedo
Fecha de entrega:	22 de marzo de 2026
Titulación o programa:	Máster en Ciencia de Datos
Área del trabajo final:	Área 1
Idioma del trabajo:	Castellano
Palabras clave:	time series forecasting; retail demand; machine learning; XGBoost; LightGBM; SHAP values; M5 Forecasting; interpretability; hierarchical forecasting; forecast reconciliation

Resumen del trabajo

Este Trabajo Final de Máster desarrolla un sistema de predicción jerárquica de demanda en retail utilizando el dataset M5 Forecasting – Walmart, caracterizado por su estructura multinivel y su elevada dimensionalidad temporal y categórica. El proyecto implementará y evaluará modelos basados en árboles de decisión (Random Forest, XGBoost y LightGBM) para la predicción simultánea de múltiples series temporales, priorizando eficiencia computacional y capacidad de generalización. De forma complementaria, se implementará un modelo basado en redes neuronales recurrentes (LSTM) con el objetivo de comparar su capacidad para capturar dependencias temporales de largo plazo frente a los modelos tabulares. Se incorporará reconciliación jerárquica mediante el método MinT (Minimum Trace), utilizando Bottom-Up como referencia comparativa, con el objetivo de garantizar coherencia estructural entre los distintos niveles de agregación del dataset. Se incorporará un análisis de interpretabilidad mediante SHAP para cuantificar la contribución marginal de las variables explicativas y analizar la estabilidad del modelo en distintos niveles jerárquicos. El trabajo se orienta a construir una solución reproducible, evaluable mediante métricas estándar del dominio (RMSE, MAE y WRMSSE, métrica oficial del dataset M5) y aplicable a escenarios reales de planificación de inventario.

Abstract

This Master's Thesis develops a hierarchical demand forecasting system for the retail sector using the M5 Forecasting – Walmart dataset, characterized by its multi level structure and high temporal and categorical dimensionality. The project will implement and evaluate tree based models (Random Forest, XGBoost, and LightGBM) for the simultaneous prediction of multiple time series, prioritizing computational efficiency and generalization capability. In addition, a recurrent neural network model (LSTM) will be implemented to compare its ability to capture long term temporal dependencies against tabular models. Hierarchical reconciliation will be incorporated through the MinT (Minimum Trace) method, using Bottom Up as a comparative baseline, with the aim of ensuring structural coherence across the different aggregation levels of the dataset. An interpretability analysis using SHAP will be included to quantify the marginal contribution of explanatory variables and assess model stability across hierarchical levels. The work aims to build a reproducible solution, evaluated through standard domain metrics (RMSE, MAE, and WRMSSE—the official metric of the M5 dataset), and applicable to real world inventory planning scenarios.

Índice general

1. Definición del TFM **6**
1.1. Descripción de la propuesta y justificación del interés . . . 6
1.2. Motivación personal . . . 6
1.3. Hipótesis . . . 7
1.4. Objetivos . . . 7
1.4.1. Objetivo principal . . . 7
1.4.2. Objetivos secundarios . . . 7
1.5. Metodología . . . 8
1.5.1. Revisión del estado del arte . . . 8
1.5.2. Preparación del conjunto de datos . . . 8
1.5.3. Modelado . . . 8
1.5.4. Interpretabilidad . . . 9
1.5.5. Visualización . . . 9
1.5.6. Enfoque de trabajo . . . 9
1.6. Planificación del proyecto . . . 10
1.6.1. Módulo 1 – Definición y planificación del TFM . . . 10
1.6.2. Módulo 2 – Estado del arte . . . 10
1.6.3. Módulo 3 – Diseño e implementación del sistema . . . 10
1.6.4. Módulo 4 – Redacción de la documentación del TFM . . . 11
1.6.5. Módulo 5 – Defensa del proyecto . . . 11
1.6.6. Planificación del proyecto . . . 12
1.6.7. Gestión de riesgos del proyecto . . . 14
1.7. Impacto en sostenibilidad, ético-social y diversidad . . . 15

2. Estado del arte **16**
2.1. Predicción de demanda en retail: problemática y enfoques clásicos . . . 16
2.1.1. Modelos de Gradient Boosting para forecasting . . . 17
2.1.2. Redes LSTM y modelos profundos para predicción de demanda . . . 18
2.2. Series temporales jerárquicas y reconciliación . . . 18
2.3. Interpretabilidad en forecasting: valores SHAP . . . 18
2.4. La competición M5 Forecasting y trabajos relacionados . . . 19
2.5. Síntesis y relevancia del trabajo . . . 21
Bibliografía . . . 21

Capítulo 1

Definición del TFM

1.1. Descripción de la propuesta y justificación del interés

La predicción de demanda condiciona directamente decisiones de reposición, planificación logística y optimización de inventarios. En entornos retail con alta granularidad y múltiples niveles jerárquicos, el modelado requiere estructuras que equilibren precisión y escalabilidad.

El dataset M5 constituye un benchmark relevante por su complejidad estructural y por incorporar información temporal, categórica y de calendario, lo que permite abordar el problema desde una perspectiva de feature engineering intensiva.

Los modelos basados en árboles resultan especialmente adecuados en este contexto por su capacidad para modelar relaciones no lineales, su robustez ante escenarios de alta dimensionalidad, su buen rendimiento en entornos tabulares con variables derivadas y su mayor eficiencia computacional frente a modelos puramente secuenciales.

La incorporación de SHAP permite analizar coherencia y estabilidad del modelo, facilitando su interpretación en un entorno profesional donde la explicabilidad es un requisito operativo.

1.2. Motivación personal

La elección de esta temática responde a un doble interés. Por un lado, profesional, dado que la predicción de demanda y la modelización de datos complejos constituyen áreas estratégicas dentro de la ingeniería de datos y la analítica avanzada. Por otro, académico, al permitir profundizar en técnicas de machine learning aplicadas a series temporales jerárquicas, así como en metodologías de evaluación rigurosas e interpretabilidad de modelos.

El dataset M5 Forecasting – Walmart ofrece un entorno de alta complejidad estructural que permite abordar un problema realista y exigente, alineado con escenarios profesionales actuales.

Asimismo, el trabajo permite analizar el equilibrio entre complejidad modelística y eficiencia computacional, cuestión relevante tanto desde la perspectiva técnica como estratégica.

1.3. Hipótesis

Los modelos basados en árboles, combinados con técnicas de reconciliación jerárquica, pueden ofrecer un rendimiento competitivo frente a modelos LSTM en la predicción jerárquica de demanda, manteniendo un menor coste computacional y proporcionando un mayor grado de interpretabilidad mediante el uso de SHAP.

1.4. Objetivos

1.4.1. Objetivo principal

Desarrollar y evaluar un sistema de predicción jerárquica de demanda aplicado al dataset M5 Forecasting – Walmart, comparando modelos basados en árboles y redes LSTM, incorporando reconciliación jerárquica mediante MinT e interpretabilidad mediante SHAP, con el fin de analizar su rendimiento predictivo y su eficiencia computacional en un contexto multinivel.

1.4.2. Objetivos secundarios

- Preparar y transformar el dataset M5 para su uso en modelos basados en árboles.
- Entrenar y comparar modelos como Random Forest, XGBoost y LightGBM.
- Evaluar el rendimiento mediante métricas adecuadas (RMSE, MAE y WRMSSE, métrica oficial del dataset M5).
- Analizar la importancia y contribución de las variables mediante SHAP values.
- Integrar la reflexión sobre sostenibilidad, ética y diversidad (CCEG).
- Implementar técnicas de reconciliación jerárquica (Bottom-Up y MinT) sobre las predicciones generadas por los distintos modelos, con el fin de garantizar coherencia estructural entre niveles agregados y desagregados.
- Desarrollar un modelo LSTM multiserie para comparar su rendimiento frente a los modelos basados en árboles.
- Analizar el coste computacional y la eficiencia relativa de los distintos enfoques modelísticos.
- Desarrollar un panel de visualización en Power BI para comunicar resultados y facilitar la interpretación de las predicciones y explicaciones del modelo.

1.5. Metodología

1.5.1. Revisión del estado del arte

La revisión del estado del arte abordará las principales técnicas de forecasting aplicadas al sector retail, con especial atención a modelos basados en árboles adaptados a series temporales y a los enfoques contemporáneos de interpretabilidad, particularmente mediante el uso de SHAP.

Esta revisión servirá de base para seleccionar técnicas y métricas que guiarán el desarrollo y comparación de los modelos propuestos.

1.5.2. Preparación del conjunto de datos

La preparación del conjunto de datos incluirá la transformación del problema a formato supervisado mediante la generación de variables lag y agregaciones móviles (rolling windows), así como la incorporación de variables de calendario y eventos relevantes. Asimismo, se aplicarán técnicas de codificación categórica eficientes y se establecerá una separación temporal estricta entre conjuntos de entrenamiento, validación y prueba, evitando cualquier forma de data leakage.

Esta preparación permitirá a los modelos basados en árboles y a la LSTM capturar patrones temporales y jerárquicos de manera consistente.

1.5.3. Modelado

El proceso de modelado se estructurará en dos enfoques complementarios.

En primer lugar, se desarrollarán modelos basados en árboles (Random Forest, XGBoost y LightGBM), adaptando el problema temporal a un formato supervisado mediante generación de variables lag y agregaciones móviles. Estos modelos permitirán capturar relaciones no lineales y gestionar eficientemente la alta dimensionalidad del dataset.

En segundo lugar, se implementará un modelo basado en redes neuronales recurrentes tipo LSTM, orientado a capturar dependencias temporales de largo plazo sin necesidad de ingeniería manual intensiva de características.

El modelo LSTM se planteará como un modelo global multiserie, entrenado simultáneamente sobre múltiples series del dataset, con el fin de capturar patrones compartidos y permitir su posterior reconciliación jerárquica bajo el mismo esquema aplicado a los modelos basados en árboles.

Las predicciones generadas por el modelo LSTM serán igualmente sometidas a los mismos procedimientos de reconciliación jerárquica, garantizando la coherencia estructural entre niveles y la comparabilidad directa entre enfoques.

Posteriormente, se aplicarán técnicas de reconciliación jerárquica, comenzando por el enfoque Bottom-Up y evaluando la viabilidad de implementar el método MinT, con el objetivo de asegurar coherencia entre predicciones de distintos niveles agregados.

El método MinT (Minimum Trace) permite reconciliar predicciones jerárquicas ajustando las previsiones base mediante una combinación lineal óptima basada en la matriz de covarianzas de los errores de predicción. A diferencia del enfoque Bottom-Up, que simplemente agrega predicciones desde el nivel más desagregado, MinT incorpora información sobre la estructura de

correlación entre errores, produciendo estimaciones coherentes y estadísticamente más eficientes bajo supuestos razonables ([15]).

La estimación de la matriz de covarianzas de errores se realizará a partir de los residuos obtenidos en validación temporal, siguiendo las recomendaciones metodológicas propuestas en la literatura especializada.

La comparación entre enfoques se realizará mediante evaluación out-of-sample, utilizando métricas RMSE, MAE y WRMSSE, esta última especialmente relevante por constituir la métrica oficial del dataset M5 Forecasting.

1.5.4. Interpretabilidad

El análisis de interpretabilidad incluirá el cálculo de valores SHAP tanto a nivel global como local, permitiendo examinar la contribución marginal de cada variable explicativa. Se analizará la consistencia entre la importancia global estimada y el comportamiento temporal observado, identificando las variables más influyentes en los distintos niveles jerárquicos.

El análisis mediante SHAP se aplicará sobre las predicciones generadas por los modelos base antes del proceso de reconciliación, dado que esta última constituye un ajuste estructural posterior y no forma parte del mecanismo interno de aprendizaje del modelo.

Este análisis facilitará la comprensión del comportamiento del modelo y permitirá interpretar la contribución de las variables en distintos niveles jerárquicos.

1.5.5. Visualización

Se desarrollará un panel en Power BI para mostrar las predicciones y explicaciones, orientado a la comunicación de resultados técnicos y la interpretación de los modelos.

1.5.6. Enfoque de trabajo

El proyecto se organizará de forma iterativa, siguiendo un esquema inspirado en metodologías ágiles. Cada módulo del aula funcionará como un ciclo de trabajo con entregables definidos, lo que permite revisar avances y ajustar tareas de manera progresiva.

El desarrollo del proyecto seguirá un enfoque incremental. En una primera fase se construirá un pipeline reproducible basado en modelos de árboles, asegurando estabilidad y validación temporal adecuada. Posteriormente, se implementará la reconciliación jerárquica mediante MinT para garantizar coherencia estructural. Una vez consolidado este marco, se desarrollará el modelo LSTM con fines comparativos. Este enfoque secuencial permite priorizar la robustez metodológica antes de incorporar modelos de mayor complejidad computacional.

Esta organización metodológica permitirá además alinear cada fase del proyecto con los hitos temporales previstos en la planificación.

1.6. Planificación del proyecto

1.6.1. Módulo 1 – Definición y planificación del TFM

Periodo: 18/02/2026 – 01/03/2026

En esta fase inicial se define el alcance del trabajo, concretando el tema del TFM, los objetivos de investigación y la metodología general del proyecto. Asimismo, se realiza una primera revisión exploratoria del dataset M5 con el fin de comprender su estructura, variables disponibles y posibles limitaciones. Finalmente, se redacta la propuesta formal del TFM, incluyendo la descripción del problema, los objetivos, el enfoque metodológico y una planificación preliminar del desarrollo del trabajo.

1.6.2. Módulo 2 – Estado del arte

Periodo: 02/03/2026 – 22/03/2026

Durante este módulo se lleva a cabo la revisión bibliográfica y técnica relacionada con el problema abordado en el TFM. Se analizan trabajos académicos y aplicaciones industriales en el ámbito del forecasting en retail, con especial atención a modelos basados en árboles, técnicas de series temporales y métodos de interpretabilidad de modelos. A partir de este análisis se redacta el capítulo de estado del arte, donde se contextualiza el problema, se describen los enfoques existentes y se justifica la metodología adoptada en el proyecto.

1.6.3. Módulo 3 – Diseño e implementación del sistema

Periodo: 23/03/2026 – 10/05/2026

Este módulo concentra la mayor parte del desarrollo técnico del proyecto. En primer lugar se realiza la preparación del dataset, incluyendo limpieza de datos, análisis exploratorio y verificación de la coherencia de las series temporales. Posteriormente se aplican transformaciones supervisadas para la generación de variables predictoras, como lags temporales, ventanas móviles y codificación de variables categóricas.

Una vez preparado el conjunto de datos, se desarrollan y entrenan diferentes modelos predictivos basados en algoritmos de árboles (RF, XGBoost y LightGBM), utilizando esquemas de validación temporal adecuados para series temporales. Sobre las predicciones obtenidas se aplican técnicas de reconciliación jerárquica, como Bottom-Up y MinT, con el objetivo de garantizar coherencia entre los distintos niveles de agregación.

Adicionalmente se realiza un análisis de interpretabilidad mediante valores SHAP, que permite identificar las variables más influyentes en las predicciones y analizar la estabilidad del modelo. De forma complementaria se implementa un modelo basado en redes neuronales recurrentes (LSTM) para comparar su comportamiento con los modelos basados en árboles. Finalmente se lleva a cabo una evaluación comparativa de los modelos mediante métricas como RMSE, MAE y WRMSSE, así como un análisis del coste computacional y de la interpretabilidad de cada enfoque.

1.6.4. Módulo 4 – Redacción de la documentación del TFM

Periodo: 11/05/2026 – 02/06/2026

En esta fase se elabora la memoria del TFM integrando los resultados obtenidos durante el desarrollo técnico. Se redactan los distintos capítulos del documento, incluyendo introducción, estado del arte, metodología, resultados experimentales y conclusiones. Posteriormente se realiza un proceso de revisión y ajuste del documento con el fin de mejorar la claridad de la exposición, la coherencia del contenido y la presentación de resultados. Finalmente se prepara el material de presentación del proyecto, incluyendo las diapositivas y el vídeo explicativo requeridos para la defensa.

1.6.5. Módulo 5 – Defensa del proyecto

Periodo: 05/06/2026 – 26/06/2026

La última fase del proyecto corresponde a la entrega oficial de la documentación final y a la preparación de la defensa pública del TFM. Durante este periodo se revisa la versión definitiva del documento, se realiza la entrega al tribunal y se prepara la exposición del trabajo. La defensa consiste en una presentación del proyecto ante el tribunal, donde se describen el problema abordado, la metodología aplicada, los resultados obtenidos y las principales conclusiones del estudio.

1.6.6. Planificación del proyecto

A continuación se presenta un resumen estructurado de la planificación del proyecto, donde se recogen las fases, subtareas, requisitos y hitos asociados. Los identificadores utilizados (M1, M2, M3-1, etc.) se mantienen de forma coherente para facilitar su correspondencia con el calendario del apartado siguiente.

ID	Fase (Módulo)	Periodo	Requisito	Actividades principales	Hito
M1	Definición (M1)	18-feb – 1-mar	-	Tema, objetivos, metodología, planificación	Propuesta aprobada
M2	Estado del arte (M2)	2-mar – 22-mar	M1 completado	Revisión bibliográfica, redacción capítulo 2	Capítulo del estado del arte validado
M3	Implementación (M3)	23-mar – 10-may	M2 completado	Desarrollo técnico completo	Pipeline técnico funcional
M3-1	Preparación de datos	23-mar – 27-mar	M2 completado	Limpieza inicial y revisión de datos	Dataset limpio y coherente
M3-2	Transformación supervisada	28-mar – 4-abr	Dataset limpio	Generación de lags, rolling windows, codificación categórica	Dataset listo para modelado
M3-3	Modelado Árboles (v1)	5-abr – 15-abr	Dataset preparado	Entrenamiento RF, XGBoost, LightGBM + validación temporal	Baseline entrenado y evaluado
M3-4	Reconciliación jerárquica	16-abr – 22-abr	Predicciones base	Implementación Bottom-Up y MinT	Predicciones jerárquicamente coherentes
M3-5	Interpretabilidad (SHAP)	23-abr – 30-abr	Modelos de árboles estables	Cálculo global/local, análisis estabilidad	Informe de importancia de variables
M3-6	LSTM multiserie	1-may – 7-may	Dataset preparado	Implementación y entrenamiento LSTM + generación de predicciones base para posterior reconciliación jerárquica	Modelo LSTM entrenado y predicciones reconciliadas coherentes
M3-7	Evaluación comparativa	8-may – 10-may	Todos los modelos	Comparación métricas RMSE/MAE/WRMSSE + coste computacional	Resultados consolidados
M4	Redacción del TFM	11-may – 2-jun	M3 completado	Redacción de la documentación	Documento final entregado

ID	Fase (Módulo)	Periodo	Requisito	Actividades principales	Hito
M4-1	Memoria preliminar	11-may – 15-may	M3 completado	Redacción inicial con resultados	Documento preliminar completo
M4-2	Memoria final	16-may – 24-may	Memoria preliminar	Revisión final y ajustes	Documento final entregado
M4-3	Presentación	25-may – 2-jun	Memoria final	Vídeo y diapositivas	Presentación audiovisual preparada
M5	Defensa del proyecto	3-jun – 26-jun	M4 completado	Entrega de la documentación final y defensa	Entrega al tribunal y defensa
M5-1	Entrega tribunal	5-jun	M4	Documentación final	Entrega oficial
M5-2	Defensa pública	26-jun	Entrega al tribunal	Exposición pública	Defensa realizada

Tabla 1.1: Resumen de la planificación del proyecto

En la Figura 1.1 se representa la planificación del proyecto mediante un diagrama de Gantt. Los códigos de cada fase y subtarea (M1, M2, M3-1...) coinciden con los utilizados en la Tabla 1.1, permitiendo visualizar de forma integrada la duración y la secuencia lógica de las actividades.

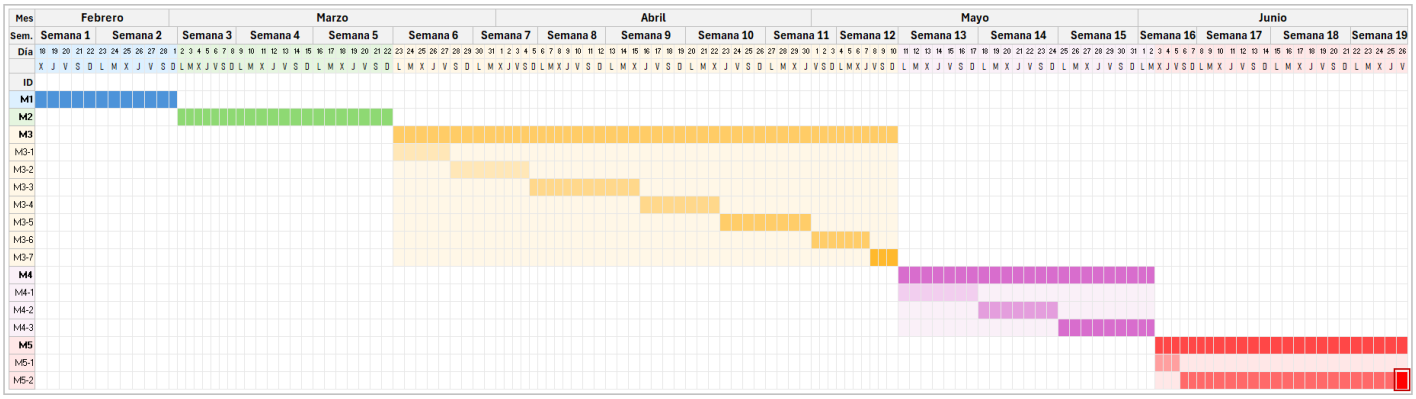

Figura 1.1: Calendario de la planificación del proyecto (formato Gantt).

La planificación permite solapamientos controlados entre fases, iniciando tareas como interpretabilidad o reconciliación jerárquica una vez establecida una primera versión del modelo base. Esto optimiza el tiempo disponible y reduce riesgos de acumulación de tareas en fases finales.

1.6.7. Gestión de riesgos del proyecto

Se identifican los siguientes riesgos potenciales:

- **Coste computacional elevado del modelo LSTM**
  Probabilidad: Media
  Impacto: Alto
  Mitigación: uso de subconjuntos jerárquicos y reducción de dimensionalidad inicial.

- **Dificultad en implementación de MinT**
  Probabilidad: Media
  Impacto: Medio
  Mitigación: priorizar Bottom-Up como método base garantizado.

- **Rendimiento similar entre modelos sin diferencias significativas**
  Probabilidad: Media
  Impacto: Bajo
  Mitigación: enfocar el análisis en interpretabilidad y eficiencia computacional.

- **Desviaciones en la planificación por complejidad técnica**
  Probabilidad: Media
  Impacto: Medio
  Mitigación: desarrollar primero un pipeline mínimo reproducible antes de optimizaciones avanzadas.

- **Riesgo de data leakage en validación temporal**
  Probabilidad: Media
  Impacto: Alto
  Mitigación: validación walk-forward estricta y separación clara por horizonte.

La gestión de riesgos se integrará de forma dinámica en la planificación temporal del proyecto. Cada hito técnico definido en la tabla de planificación funcionará como punto de control para evaluar desviaciones y activar medidas de mitigación, especialmente en las fases de modelado y reconciliación jerárquica.

Cada riesgo será evaluado al final de su fase correspondiente, usando los hitos técnicos como punto de control.

1.7. Impacto en sostenibilidad, ético-social y diversidad

Desde la dimensión de sostenibilidad, una mejora en la precisión de los modelos de predicción de demanda puede contribuir a reducir la sobreproducción, el desperdicio de productos y los costes logísticos asociados al transporte y almacenamiento, alineándose con objetivos de eficiencia operativa y reducción del impacto ambiental.

Asimismo, se considerará la eficiencia computacional y energética de los modelos desarrollados, analizando el impacto relativo de arquitecturas más complejas como LSTM frente a modelos basados en árboles, en línea con enfoques de inteligencia artificial sostenible.

En cuanto al comportamiento ético y responsabilidad social, el dataset M5 se encuentra completamente anonimizado, sin incluir datos personales, garantizando el respeto a la privacidad y el cumplimiento de normativas de protección de datos. Además, se enfatiza que los modelos desarrollados deben utilizarse como herramientas de apoyo a la toma de decisiones y no como mecanismos automatizados excluyentes.

Finalmente, el uso de datasets públicos procedentes de plataformas abiertas como Kaggle fomenta la accesibilidad, la igualdad de oportunidades en investigación y la colaboración global, promoviendo la diversidad en el desarrollo y evaluación de soluciones de inteligencia artificial.

Capítulo 2

Estado del arte

Aunque existen numerosos estudios que analizan modelos basados en boosting, redes LSTM o técnicas de reconciliación jerárquica de forma independiente, no es habitual encontrar trabajos que integren estos enfoques dentro de un mismo marco metodológico. Este hecho justifica la relevancia del presente trabajo, que propone una comparación entre modelos basados en árboles y redes LSTM, incorporando técnicas de reconciliación jerárquica mediante MinT e interpretabilidad mediante SHAP.

La predicción de demanda en retail ha sido ampliamente estudiada debido a su impacto en la planificación de inventarios, la gestión logística y la toma de decisiones. Estos entornos presentan una elevada complejidad estructural: miles de series temporales interrelacionadas, múltiples niveles jerárquicos, estacionalidad, efectos de calendario y variaciones derivadas de promociones o cambios de precio ([7]). Este contexto ha favorecido el uso de modelos capaces de manejar grandes volúmenes de datos y capturar relaciones no lineales.

El dataset M5 Forecasting – Walmart ([12]) constituye un benchmark relevante por su estructura jerárquica profunda, granularidad diaria y diversidad de variables explicativas, permitiendo comparar modelos estadísticos y de machine learning bajo un mismo marco.

2.1. Predicción de demanda en retail: problemática y enfoques clásicos

La demanda en retail está influida por múltiples factores simultáneos: estacionalidad, tendencias, eventos, promociones, variaciones de precio y diferencias entre tiendas o regiones, tal como se observa en distintos enfoques de modelización de demanda. La presencia de miles de series con comportamientos heterogéneos ha impulsado el desarrollo de modelos globales, capaces de aprender patrones compartidos entre productos y tiendas ([14]).

Los métodos univariantes como ARIMA o ETS han sido ampliamente utilizados, pero presentan limitaciones al abordar estructuras jerárquicas complejas y múltiples variables explicativas ([7]). Esta limitación ha favorecido la adopción de modelos más flexibles y escalables.

Para contextualizar esta transición, es necesario detallar brevemente el funcionamiento de los modelos clásicos. ARIMA modela la serie temporal como una combinación lineal de tres componentes: (i) un término autorregresivo (AR) basado en rezagos de la propia serie, (ii) un término de diferenciación (I) que busca

garantizar estacionariedad y (iii) un componente de medias móviles (MA) que incorpora errores pasados. Este enfoque asume relaciones lineales y una estructura temporal relativamente simple.

SARIMA extiende ARIMA incorporando términos estacionales adicionales (AR, I y MA estacionales), lo que permite capturar patrones repetitivos como los semanales o mensuales. Sin embargo, ambos modelos presentan limitaciones importantes: requieren estacionariedad, no integran de forma natural múltiples variables explicativas, no capturan relaciones no lineales y escalan mal cuando se trabaja con miles de series simultáneamente.

Estas limitaciones motivaron la adopción de modelos más flexibles y escalables, como los métodos de gradient boosting y las redes LSTM, que se desarrollan en las subsecciones siguientes. En particular, estos enfoques permiten modelar relaciones no lineales, incorporar múltiples variables explicativas y escalar de forma eficiente a conjuntos de datos con un gran número de series temporales, superando algunas de las restricciones inherentes a los modelos clásicos.

2.1.1. Modelos de Gradient Boosting para forecasting

Los modelos basados en árboles, como Random Forest ([1]), XGBoost ([2]) y LightGBM ([9]), presentan un rendimiento destacado en datos tabulares de alta dimensionalidad. En la competición M5, los modelos de gradient boosting fueron predominantes entre las soluciones mejor posicionadas ([12]).

La literatura indica que, combinados con un feature engineering adecuado – lags, ventanas móviles, variables de calendario y de precio –, pueden ofrecer un rendimiento competitivo frente a modelos más complejos como las redes neuronales recurrentes ([3]). Esto respalda su uso como base en el presente trabajo.

Desde un punto de vista técnico, los modelos de gradient boosting construyen árboles de decisión de manera secuencial: cada nuevo árbol se entrena para corregir los errores residuales del árbol anterior. Este proceso iterativo permite capturar relaciones no lineales y manejar interacciones complejas entre variables sin necesidad de especificarlas explícitamente.

Este enfoque se basa en un esquema de aprendizaje aditivo, en el que cada nuevo modelo se centra en corregir los errores acumulados, optimizando de forma iterativa una función de pérdida definida sobre el conjunto de entrenamiento.

Modelos como XGBoost y LightGBM incorporan técnicas avanzadas de regularización, manejo eficiente de memoria, histogramas para acelerar la búsqueda de divisiones y estrategias de reducción del sobreajuste. Estas características los hacen especialmente adecuados para problemas de forecasting con grandes volúmenes de datos, múltiples variables explicativas y estructuras jerárquicas profundas.

Su principal limitación es que no modelan explícitamente la dependencia temporal de largo plazo, ya que trabajan sobre features tabulares generadas manualmente (lags, ventanas, calendarios). Esto ha impulsado el uso de modelos secuenciales como las LSTM.

2.1.2. Redes LSTM y modelos profundos para predicción de demanda

Las redes neuronales recurrentes, en particular las LSTM ([4]), están diseñadas para capturar dependencias temporales de largo plazo sin necesidad de ingeniería manual intensiva. Gracias a esta arquitectura, las LSTM son capaces de capturar dependencias temporales complejas y patrones de largo plazo en las series, reduciendo la necesidad de ingeniería manual de variables basada en retardos.

Las LSTM incorporan una arquitectura basada en "celdas de memoria" y tres puertas (entrada, olvido y salida) que regulan qué información se mantiene, cuál se descarta y cuál se transmite a pasos futuros. Esta estructura permite mitigar el problema del desvanecimiento del gradiente y facilita el aprendizaje de patrones temporales complejos.

A pesar de estas ventajas, presentan limitaciones relevantes: requieren grandes volúmenes de datos limpios, son sensibles a la configuración de hiperparámetros, tienen un coste computacional elevado y ofrecen menor interpretabilidad que los modelos basados en árboles. En la competición M5, su rendimiento fue inferior al de los modelos boosting, lo que ha generado debate sobre su aplicabilidad en entornos productivos.

Su inclusión en este trabajo permite comparar enfoques tabulares y secuenciales bajo un mismo marco metodológico, evaluando no solo la precisión, sino también la eficiencia computacional y la interpretabilidad.

2.2. Series temporales jerárquicas y reconciliación

La estructura jerárquica de los datos constituye un elemento central del problema. En el caso de Walmart, las ventas pueden agregarse por estado, tienda, categoría o producto, generando distintos niveles que deben mantener coherencia entre sí.

Los enfoques tradicionales como Bottom-Up, Top-Down o Middle-Out ([6]) permiten agregar o desagregar predicciones, pero no consideran la correlación entre errores de predicción.

Para abordar esta limitación, [15] proponen MinT (Minimum Trace), que ajusta las predicciones base mediante una combinación lineal que minimiza la traza de la matriz de covarianzas de los errores, lo que equivale a minimizar la varianza total de los errores reconciliados bajo una combinación lineal óptima. Este enfoque produce predicciones más eficientes y coherentes, especialmente en jerarquías profundas como la del M5. Por ello, en este trabajo se emplea MinT como técnica principal, complementada con Bottom-Up como referencia.

La necesidad de garantizar coherencia jerárquica requiere modelos capaces de generar predicciones base robustas.

2.3. Interpretabilidad en forecasting: valores SHAP

La interpretabilidad constituye un requisito clave en aplicaciones empresariales. Los valores SHAP ([10]) se han consolidado como una herramienta estándar para explicar modelos complejos, especialmente los basados en árboles. SHAP permite analizar la contribución marginal

de cada variable, identificar patrones y evaluar la estabilidad del modelo. En este trabajo se aplica sobre las predicciones base, dado que la reconciliación constituye un ajuste posterior.

Además de su utilidad técnica, la interpretabilidad desempeña un papel fundamental en la adopción real de modelos de forecasting dentro de organizaciones retail. En estos entornos, los equipos de negocio necesitan comprender por qué un modelo predice un aumento o disminución de la demanda, especialmente cuando las decisiones afectan a inventario, promociones o asignación de recursos.

Los valores SHAP permiten identificar qué variables impulsan la predicción en cada instante, facilitando la detección de patrones relevantes como efectos de precio, estacionalidad o impacto de promociones. Esta información puede emplearse para diseñar campañas comerciales más efectivas, ajustar estrategias de pricing o priorizar productos con alta sensibilidad a determinados factores.

Asimismo, SHAP favorece la comunicación entre perfiles técnicos y no técnicos, reduciendo la percepción de "caja negra" asociada a modelos complejos. Esto incrementa la confianza en el sistema de forecasting y facilita su integración en procesos de toma de decisiones operativas y estratégicas.

En entornos retail, donde las decisiones deben justificarse ante múltiples áreas, la interpretabilidad resulta especialmente relevante para garantizar la adopción efectiva de los modelos y asegurar que las predicciones puedan ser comprendidas, validadas y utilizadas en la práctica.

2.4. La competición M5 Forecasting y trabajos relacionados

El dataset M5 ha dado lugar a numerosos trabajos académicos y soluciones industriales.

Aunque existen trabajos centrados en modelos boosting, otros en LSTM y algunos en reconciliación jerárquica, no es habitual encontrar un enfoque que integre estos elementos en un mismo pipeline orientado a la comparación sistemática.

Las soluciones mejor posicionadas compartieron varios elementos clave: (i) el uso de modelos globales entrenados sobre todas las series simultáneamente, lo que permitió capturar patrones comunes entre productos y tiendas; (ii) un feature engineering muy intensivo, incluyendo lags, medias móviles, indicadores de calendario, variables de precio y variables derivadas de eventos; y (iii) una optimización exhaustiva de hiperparámetros mediante técnicas como grid search o Bayesian optimization.

El equipo ganador (1st place), según la documentación oficial de Kaggle, utilizó un modelo LightGBM global con un conjunto de más de 300 variables derivadas y obtuvo un WRMSSE de 0.520. El segundo y tercer clasificado también emplearon modelos boosting (LightGBM o CatBoost), con WRMSSE en rangos muy próximos al ganador (∼0.52-0.53), lo que evidencia que las diferencias entre las mejores soluciones fueron mínimas y dependieron principalmente de ajustes finos en la ingeniería de características.

El análisis del repositorio oficial de la competición muestra que las redes neuronales profundas, incluidas las LSTM, obtuvieron resultados inferiores en la ma-

yoría de los casos, debido a su mayor complejidad, sensibilidad al preprocesado y dificultad para capturar patrones idiosincráticos en miles de series cortas. Este comportamiento coincide con los hallazgos del paper oficial de la M5, que destaca el dominio de los modelos boosting en contextos de forecasting retail con estructuras jerárquicas profundas.

A continuación, se presenta un resumen estructurado de las soluciones mejor clasificadas en la competición, incluyendo sus principales características y métricas, que servirán como referencia comparativa para los experimentos desarrollados en este trabajo (Tabla 2).

Posición	**Equipo / Autor**	**Modelo principal**	**Características clave**	**WRMSSE**	**Fuente**
1º	Kailex	LightGBM global	Feature engineering intensivo (>300 variables), modelo global, tuning exhaustivo	0.52	[8]
2º	Matthias	LightGBM	Ventanas temporales optimizadas, variables de precio, regularización avanzada	$\sim$ 0,52–0,53	[5]
3º	Rob Mulla (Robikscube)	LightGBM + modelos globales	Feature engineering profundo, validación cruzada por series	$\sim$ 0,53	[13]
Top 10	Varios	LightGBM / CatBoost	Variaciones en ingeniería de variables y tuning	0.52–0.54	[11]
Paper oficial	Makridakis et al. (2020)	—	Análisis de resultados y patrones comunes	—	[12]

Tabla 2. Resumen de las soluciones mejor clasificadas en la competición M5 (Accuracy Track).

2.5. Síntesis y relevancia del trabajo

La literatura muestra que la predicción de demanda en estructuras jerárquicas requiere modelos capaces de manejar alta dimensionalidad, capturar patrones temporales y mantener coherencia entre niveles. Se observa un claro predominio de enfoques centrados de forma aislada en modelos boosting, modelos profundos o técnicas de reconciliación jerárquica. Sin embargo, estos trabajos rara vez abordan de forma conjunta la interacción entre precisión predictiva, coherencia jerárquica, coste computacional e interpretabilidad dentro de un mismo marco experimental. En este contexto, el presente trabajo propone una aproximación integradora que combina estos elementos en un único pipeline reproducible, permitiendo evaluar de forma sistemática no solo el rendimiento predictivo, sino también las implicaciones prácticas de cada enfoque en términos de escalabilidad, interpretabilidad y aplicabilidad en entornos reales de retail. La reconciliación jerárquica mediante MinT se consolida como un componente clave para asegurar coherencia estructural, mientras que SHAP facilita la interpretación de modelos complejos y su adopción por parte de perfiles no técnicos.

La revisión de la competición M5 confirma el predominio de los modelos boosting – especialmente LightGBM – en contextos de forecasting retail con jerarquías profundas. En línea con lo observado en la competición M5, las soluciones mejor clasificadas comparten patrones claros: uso de modelos globales, feature engineering intensivo y optimización exhaustiva de hiperparámetros. Estas estrategias permitieron alcanzar valores WRMSSE en el rango **0.52-0.53**, que constituyen el **benchmark de referencia** para evaluar el rendimiento de los modelos desarrollados en este trabajo.

A pesar de estos avances, la literatura carece de un análisis integrado que combine modelos boosting, redes LSTM, reconciliación jerárquica e interpretabilidad dentro de un mismo marco metodológico. Este trabajo aborda dicho vacío mediante una comparación sistemática que evalúa precisión, coherencia jerárquica, coste computacional e interpretabilidad en el contexto del dataset M5. Esta aproximación permite no solo contrastar el rendimiento de los distintos modelos, sino también situar los resultados obtenidos frente a los estándares establecidos por las soluciones más exitosas de la competición.

Bibliografía

[1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. https://link.springer.com/article/10.1023/A:1010933404324.

[2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016. https://dl.acm.org/doi/10.1145/2939672.2939785.

[3] Hansika Hewamalage, Christoph Bergmeir, and Kasun Bandara. Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 2021. https://www.sciencedirect.com/science/article/pii/S0169207020300996.

[4] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. https://www.bioinf.jku.at/publications/older/2604.pdf.

[5] Rob Holbrook. M5 forecasting accuracy: 2nd place solution. https://www.kaggle.com/competitions/m5-forecasting-accuracy/writeups/matthias-2nd-place-solution, 2020. Kaggle Competition Writeup.

[6] Rob J. Hyndman, Roman A. Ahmed, George Athanasopoulos, and Han Lin Shang. Optimal combination forecasts for hierarchical time series. *Computational Statistics and Data Analysis*, 55(9):2579–2589, 2011. https://www.sciencedirect.com/science/article/pii/S0167947311001034.

[7] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, 3rd edition, 2021. https://otexts.com/fpp3/.

[8] Kailex. M5 forecasting accuracy: 1st place solution. https://www.kaggle.com/competitions/m5-forecasting-accuracy/writeups/yeonjun-in-stu-1st-place-solution, 2020. Kaggle Competition Writeup.

[9] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, pages 3146–3154, 2017. https://papers.nips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html.

[10] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, pages 4765–4774, 2017. https://

papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.

[11] M5 Competition. M5 methods repository. https://github.com/Mcompetitions/M5-methods, 2020.

[12] Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m5 competition: Background, organization, and evaluation. *International Journal of Forecasting*, 2021. https://www.sciencedirect.com/science/article/pii/S0169207021001874.

[13] R. (Robikscube) Mulla. M5 forecasting accuracy: 3rd place solution. https://www.kaggle.com/competitions/m5-forecasting-accuracy/writeups/mf-3rd-place-solution-nn-approach, 2020. Kaggle Competition Writeup.

[14] David Salinas, Valentin Flunkert, Jan Gasthaus, and Tim Januschowski. Deepar: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191, 2017. https://arxiv.org/pdf/1704.04110.pdf.

[15] Shanika L. Wickramasuriya, George Athanasopoulos, and Rob J. Hyndman. Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. *Journal of the American Statistical Association*, 114(526):804–819, 2019. https://www.tandfonline.com/doi/full/10.1080/01621459.2018.1448825.